Laporan Analisis Data Mining

EDA Spotify Dataset

Nama: Syauqi Nabil Tasri
NRP: 5054241040
Asdos: Richard

---

1. Deskripsi Dataset

   Pada notebook, saya telah melakukan beberapa pengecekan seperti mengecek 5 baris teratas, tipe data tiap fitur, dan dimensi dataset. Dengan hasil seperti berikut:

	user_id	gender	age	country	subscription_type	listening_time	songs_played_per_day	skip_rate	device_type	ads_listened_per_week	offline_listening	is_churned
0	1	Female	54	CA	Free	26	23	0.20	Desktop	31	0	1
1	2	Other	33	DE	Family	141	62	0.34	Web	0	1	0
2	3	Male	38	AU	Premium	199	38	0.04	Mobile	0	1	1
3	4	Female	22	CA	Student	36	2	0.31	Mobile	0	1	0
4	5	Other	29	US	Family	250	57	0.36	Mobile	0	1	1

   Kita dapat melihat bahwa dataset memiliki 12 kolom yaitu user_id, gender, age, country, subscription_type, listening_time, songs_played_per_day, skip_rate, device_type, ads_listened_per_week, offline_listening, is_churned. Dan selanjutnya saya untuk pengecekan deskripsi setiap fitur dengan menggunakan fungsi .info(), hasilnya seperti berikut:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8000 entries, 0 to 7999
Data columns (total 12 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   user_id                 8000 non-null   int64
 1   gender                  8000 non-null   object
 2   age                     8000 non-null   int64
 3   country                 8000 non-null   object
 4   subscription_type       8000 non-null   object
 5   listening_time          8000 non-null   int64
 6   songs_played_per_day    8000 non-null   int64
 7   skip_rate               8000 non-null   float64
 8   device_type             8000 non-null   object
 9   ads_listened_per_week   8000 non-null   int64
 10  offline_listening       8000 non-null   int64
 11  is_churned              8000 non-null   int64
dtypes: float64(1), int64(7), object(4)
memory usage: 750.1+ KB
None
```

   Berdasarkan deskripsi tersebut, kita dapat mengetahui bahwa ada 8 fitur dengan tiper numerik (int64, float64) dan 4 fitur dengan tipe kategorikal (object). Tapi, di 5 baris teratas sebelumnya kita melihat kalau fitur offline_listening dan is_churned berisi 1 dan 0 saja. Jika 2 kolom tersebut hanya berisi 1 dan 0, maka fitur tersebut bukan termasuk numerik tapi kategorikal. Kita dapat melakukan pengecekan dengan menggunakan fungsi .nunique() untuk melihat berapa banyak nilai unik di setiap kolom dengan hasil sebagai berikut:

	e
user_id	8000
gender	3
age	44
country	8
subscription_type	4
listening_time	290
songs_played_per_day	99
skip_rate	61
device_type	3
ads_listened_per_week	46
offline_listening	2
is_churned	2

Nah, berdasarkan output nya, kita dapat melihat bahwa fitur offline_listening dan is_churned hanya memiliki 2 nilai unik yang mana hanya 1 dan 0 dan kedua fitur ini pun masuk kedalam tipe kategorikal.

2. Statistik Deskriptif

Selanjutnya yaitu analisa deskripsi statistik pada fitur numerik menggunakan fungsi .describe() dengan hasil sebagai berikut:

	age	listening_time	songs_played_per_day	skip_rate	ads_listened_per_week
count	8000.000000	8000.000000	8000.000000	8000.000000	8000.000000
mean	37.662125	154.068250	50.127250	0.300127	6.943875
std	12.740359	84.015596	28.449762	0.173594	13.617953
min	16.000000	10.000000	1.000000	0.000000	0.000000
25%	26.000000	81.000000	25.000000	0.150000	0.000000
50%	38.000000	154.000000	50.000000	0.300000	0.000000
75%	49.000000	227.000000	75.000000	0.450000	5.000000
max	59.000000	299.000000	99.000000	0.600000	49.000000

Berdasarkan hasil ini kita dapat melihat beberapa informasi seperti mean, median (50%), modus, std_sample serta nilai min dan max di masing – masing fitur. Berdasarkan deskripsi dataset tersebut, dataset berisi 8.000 pengguna dengan age 16–59 tahun (median ≈38; Q1–Q3: 26–48), menunjukkan sebaran umur yang cukup merata tanpa ekor ekstrem; listening_time 10–299 menit per hari dengan mean≈median≈154 dan rentang antar-kuartil 81–227, menandakan distribusi relatif simetris namun lebar; songs_played_per_day tampak hampir uniform (min 1, max 99, median 50, Q1–Q3: 25–75) sehingga frekuensinya tersebar merata di rentang 1–99; skip_rate berada dalam domain 0–0,6 dengan median 0,30 (Q1–Q3: 0,15–0,45) yang mencerminkan tingkat skip moderat dan distribusi cukup seimbang; sementara ads_listened_per_week sangat "zero-inflated": median 0 dan Q3=5 mengindikasikan sebagian besar pengguna tidak mendengar iklan (kemungkinan premium), tetapi ada ekor kanan hingga 49 pada kelompok non-premium; keseluruhan metrik (mean≈median pada sebagian besar fitur) menyiratkan distribusi yang tidak terlalu skew dan kecil kemungkinan outlier ekstrem menurut aturan IQR standar.

3. Penanganan Data

Selanjutnya yaitu melakukan cek ke missing value di masing masing fitur menggunakan fungsi .isnull() untuk mengidentifikasi nilai yang hilang dan menjumlahkan totalnya per baris menggunakan fungsi .sum(). Hasilnya sebagai berikut:

	0
user_id	0
gender	0
age	0
country	0
subscription_type	0
listening_time	0
songs_played_per_day	0
skip_rate	0
device_type	0
ads_listened_per_week	0
offline_listening	0
is_churned	0

Disini terlihat bahwa pada dataset tersebut di seluruh fiturnya tidak terdapat satupun nilai yang hilang, jadi kita tidak perlu melakukan penanganan terhadap missing value. Tapi jika di dataset terdapat missing value, kita dapat melakukan beberapa penanganan seperti menghapus baris / kolom yang ada missing value, mengisi nya dengan rata rata / median, dan lain lain.

Tidak hanya missing value saja, kita juga perlu melakukan cek ke outlier di fitur numerik. Kita tidak melakukan cek outlier ke fitur kategorikal karena fitur kategorikal isinya hanya beberapa data saja (missal: 2, 4, 6) dan tidak mungkin ada data yang diluar batas. Disini saya melakukan cek outlier menggunakan 4 cara yaitu boxplot, IQR, z-score, dan MAD. Dan hasilnya pada setiap cara pengecekan outlier tersebut tidak terdeteksi outlier satupun. Jadi kita juga tidak perlu melakukan penanganan terhadap outlier. Dan jika terdapat outlier, kita bisa melakukan beberapa penanganan seperti menggunakan winsorizer, robust scaler, dan lain lain.

Dikarenakan visualisasi boxplot nya banyak, maka untuk detail lengkap nya bisa di cek di notebook.

4. Visualisasi & Interpretasi

Selanjutnya yaitu visualisasi dari beberapa fitur seperti visualisasi histogram distribusi pada fitur songs_played_per_day, scatter plot antara fitur age dan listening_time, dan bar chart pada fitur subscription_type.

a. Histogram: distribusi songs_played_per_day

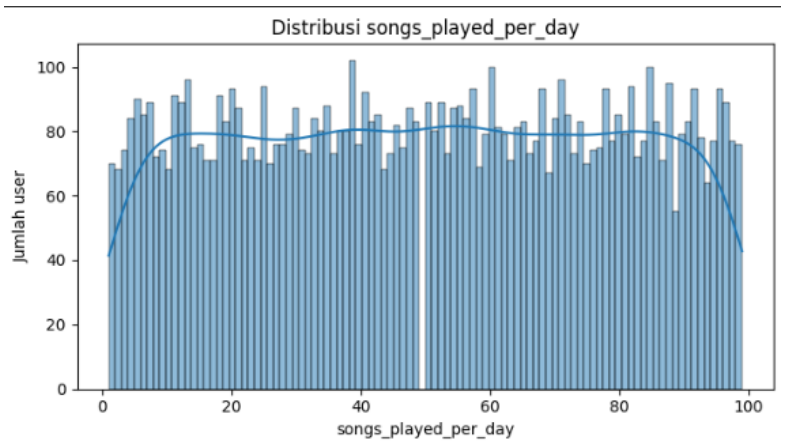

Pada grafik songs_played_per_day, menunjukkan sebaran yang nyaris uniform di rentang 1–99 lagu/hari: tidak ada skew berarti, puncak/bukit spesifik, atau ekor berat. Garis KDE yang sedikit turun di ujung kiri/kanan adalah boundary bias (wajar karena domain terbatas). Celah tipis di

sekitar ~50 itu kemungkinan artefak binning (tepi bin jatuh pas di nilai integer tertentu), bukan "lubang" nyata pada data. Dengan bentuk seperti ini, deteksi outlier berbasis IQR/Z/MAD hampir tidak akan menandai apa pun (sudah dibuktikan tadi), dan transformasi (log, Box-Cox) tidak diperlukan, cukup standardize bila modelnya sensitif skala (KNN/SVM).

b. Scatter plot: hubungan antara age dan listening_time

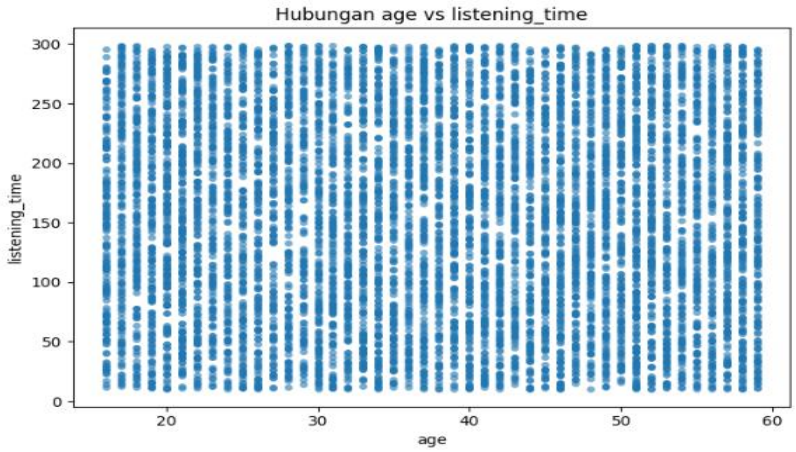

Dari visualisasi ini, kita dapat melihat bahwa hubungan antara kedua fitur ini sangat kecil karena titik titik yang ada pada scatter plot tersebut menyebar kemana mana dan tidak terbentuk pola. Saya juga sudah membuktikannya dengan menggunakan heatmap correlation dengan metode pearson dan didapat hasil seperti ini:

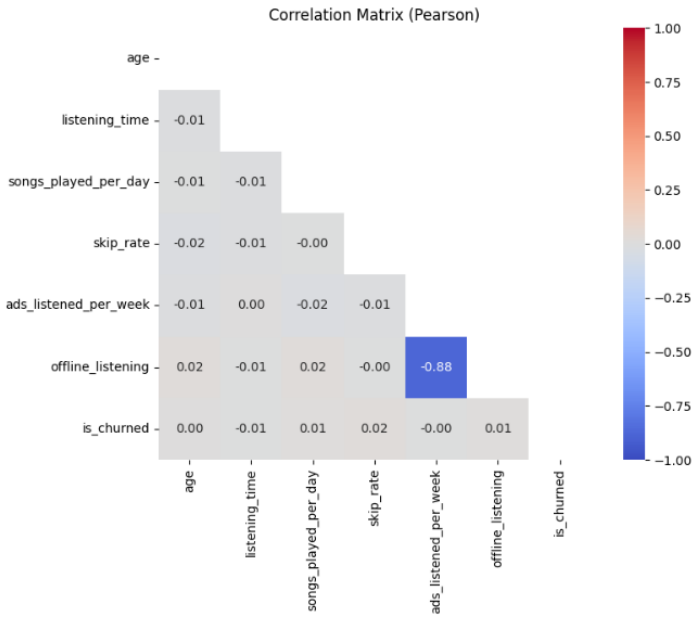

Kita bisa lihat bahwa nilai korelasi antar fitur memang sangat tipis kecuali untuk offline_listening dengan ads_listened_per_week, karena ketika offline_listening nya True maka tidak mungkin si user menonton satu iklan.

c. Bar chart: jumlah user berdasarkan subscription_type

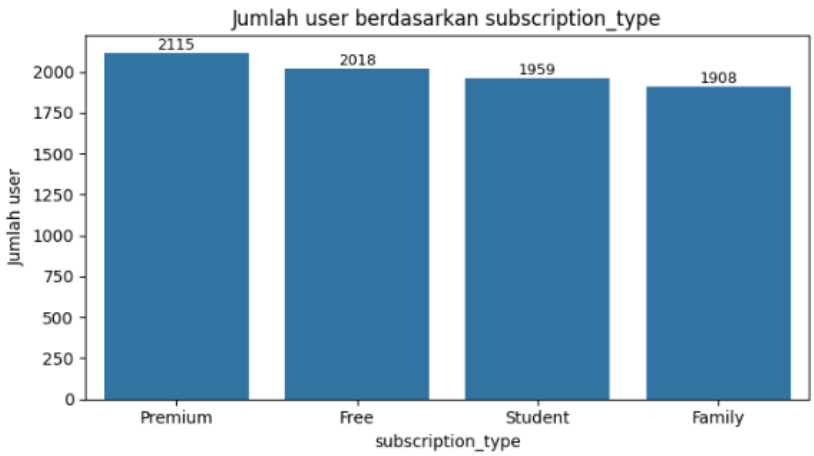

Pada Bar chart ini nunjukin distribusi kategori subscription_type yang sangat seimbang: Premium 2115 (~26.4%), Free 2018 (~25.2%), Student 1959 (~24.5%), Family 1908 (~23.9%) dari total 8.000 user. Selisih terbesar antar-kategori cuma ~2.5 poin persentase, jadi tidak ada class imbalance yang mana berarti sangat bagus untuk analisis komparatif dan model klasifikasi (bisa pakai stratified split pakai kolom ini). Secara domain, ini juga konsisten dengan temuan korelasi: kategori yang identik dengan premium kemungkinan berkaitan dengan ads_listened_per_week = 0 dan offline_listening > 0.